

Comportamento do Consumidor

Pipeline de dois agentes para análise de sentimento e geração de insights de marketing a partir de avaliações reais de e-commerce

Integrantes: Pedro Aragão · Manuela Borges · Arthur Rocha · Camila

Base de dados: Olist Brazilian E-Commerce (~100 mil avaliações)

Ambiente: Google Colab · Python

1. Objetivo do projeto

O projeto implementa um sistema de **dois agentes** que analisa comentários reais de consumidores brasileiros e converte essa análise em recomendações práticas para uma equipe de marketing. A premissa central é usar a **nota de 1 a 5** que acompanha cada avaliação como rótulo supervisionado — ou seja, o próprio cliente, ao dar a nota, "ensina" o modelo a reconhecer sentimento em português, sem necessidade de rotulagem manual.

2. Base de dados

Foi utilizada a base pública **Olist Brazilian E-Commerce**, que contém cerca de 100 mil avaliações reais de compras em e-commerce no Brasil. Cada registro traz a nota atribuída pelo cliente (`review_score`, de 1 a 5) e o comentário em texto livre (`review_comment_message`). Aproximadamente 41 mil avaliações possuem texto escrito — o universo de trabalho do projeto.

DECISÃO DE ESCOPO

O escopo inicial previa coleta via API (ex.: Mercado Livre). Optou-se pela base Olist por três motivos: ela já entrega o par *texto + nota* pronto (eliminando a fragilidade de depender de uma API ao vivo no dia da entrega), é um dataset acadêmico consagrado, e seu volume permite um treino supervisionado robusto. O CSV bruto é o "dado grosseiro sem tratamento" — exatamente o ponto de partida do Agente 1.

3. Arquitetura: os dois agentes

Agente 1 — Coletor & Curador

Responsável por transformar o dado bruto em uma base limpa e estruturada. Suas etapas:

- Lê o CSV bruto e filtra as avaliações que possuem texto.
- Diagnostica o ruído (quebras de linha, maiúsculas, duplicatas, comentários curtíssimos).
- Aplica limpeza de português informal: remoção de emojis preservando acentos, redução de letras esticadas ("ameeei" → "amei") e expansão de gírias ("vc" → "você", "mt" → "muito").
- Cria o rótulo de sentimento a partir da nota: 1–2 = negativo, 3 = neutro, 4–5 = positivo.

entrada: ~99 mil registros brutos

saída: ~35 mil comentários curados

Agente 2 — Analista & Consultor de Marketing

Recebe a base curada e cumpre três funções:

- **Treino supervisionado:** vetorização TF-IDF (unigramas e bigramas) e treino de um classificador, usando a nota como gabarito.
- **Avaliação e interpretação:** métricas de desempenho, matriz de confusão e extração das palavras que mais indicam cada sentimento.
- **Análise de aspectos:** detecção dos temas mais citados — entrega/prazo, qualidade, preço, atendimento e expectativa — cruzados com o sentimento.

TF-IDF + Regressão Logística

comparação com LinearSVC

class_weight balanceado

4. Modelo de análise de sentimento

Adotou-se uma abordagem **supervisionada clássica** (TF-IDF + Regressão Logística) em vez de redes neurais pesadas. A escolha se justifica pela execução rápida sem GPU, pela interpretabilidade total (é possível ver quais palavras dirigem cada sentimento, o que alimenta os insights de marketing) e por boa acurácia no volume de dados disponível. Comparou-se a Regressão Logística com o LinearSVC; a primeira foi adotada como modelo principal por entregar melhor F1-macro (equilíbrio entre as três classes) e por fornecer probabilidades e interpretabilidade.

~79%

ACURÁCIA GERAL

>0,80

F1 POSITIVO / NEGATIVO

~35 mil

COMENTÁRIOS TREINADOS

O desempenho é forte nas classes positivo e negativo — as que importam para decisões de marketing. A classe neutro tem desempenho mais fraco, o que é esperado e foi reportado de forma transparente: a nota 3 é intrinsecamente ambígua e seus comentários misturam elogios e críticas, confundindo qualquer classificador.

5. Análise de aspectos e o consultor de marketing

Classificar o sentimento é apenas metade do trabalho. Para a equipe de marketing, a pergunta real é *sobre o quê* os clientes reclamam ou elogiam. O sistema detecta a presença de temas-chave em cada comentário e os cruza com o sentimento, permitindo afirmações precisas como "a insatisfação se concentra em prazo de entrega", em vez de apenas "X% dos clientes estão insatisfeitos".

Camada conversacional (chatbot via API Anthropic)

A camada final do Agente 2 é um **chatbot consultivo** que recebe as estatísticas reais calculadas pelo pipeline e responde a perguntas da equipe de marketing, sempre ancorado nos percentuais dos dados — não em achismo. Foi implementado com a API da Anthropic (modelo Sonnet) e conta com uma interface de chat interativa (ipywidgets) que mantém histórico de conversa, permitindo perguntas de acompanhamento.

Aspecto citado	Em comentários negativos	Em comentários positivos
Entrega / Prazo	~59%	~57%
Qualidade do Produto	~57%	~50%
Atendimento	~18%	~12%
Expectativa / Anúncio	~16%	~12%
Preço / Custo	~7%	~5%

PRINCIPAL ACHADO DE NEGÓCIO

A insatisfação dos clientes se concentra em **entrega/prazo** e **qualidade do produto** — e não em preço (citado em apenas ~7% das reclamações). Para o marketing, isso indica que comunicar confiabilidade logística e qualidade tende a gerar mais impacto do que competir por preço.

6. Stack técnica

Componente	Tecnologia
Manipulação de dados	pandas, numpy
Limpeza de texto	expressões regulares (re), dicionário de gírias PT-BR
Vetorização e modelo	scikit-learn (TfidfVectorizer, LogisticRegression, LinearSVC)
Visualização	matplotlib (matriz de confusão, gráfico de aspectos)
Camada conversacional	API Anthropic (Claude Sonnet) + ipywidgets
Ambiente	Google Colab, com base hospedada no Google Drive

7. Conclusão e evoluções futuras

O projeto entregou um pipeline completo de dois agentes: o primeiro transformou avaliações brutas em uma base curada com rótulos de sentimento derivados das notas; o segundo treinou um modelo supervisionado interpretável, identificou os aspectos que mais geram insatisfação e disponibilizou um consultor de marketing que traduz os dados em recomendações acionáveis. Todo o trabalho está consolidado em um único notebook auto-documentado, validado de ponta a ponta.

Como evoluções futuras, destacam-se: o *fine-tuning* de um modelo BERTimbau (BERT em português) para ganho de acurácia, especialmente na classe neutro; a aplicação de ABSA com modelos neurais para detecção de aspectos mais sutil; e o desenvolvimento de um dashboard interativo para a equipe de marketing.